

¿Vale la pena leer el orden de las transacciones?

Informe al Comité de Riesgos — Banco del Altiplano — Monitoreo transaccional

Cindy Gualim (21226) — Gadiel Ocaña (231270) — 4 de septiembre de 2026

Recomendación: complementar el motor actual, no reemplazarlo.

Conservar las variables agregadas como decisor y añadir el puntaje secuencial como señal de priorización de la cola de revisión.

El área de riesgos tenía razón: **el orden contiene información que las variables agregadas no capturan, y lo demostramos**. Pero esa información está concentrada en un solo patrón de fraude y, con los datos disponibles, **todavía no se traduce en un ahorro medible**. Las dos cosas son ciertas a la vez, y presentar solo la primera sería engañoso.

1. Integridad de los datos

Construimos un simulador de transacciones porque permite algo que ningún conjunto real permite: saber con certeza cuáles fraudes dependen del orden y cuáles no. Sin esa certeza, cualquier ventaja del modelo secuencial sería imposible de atribuir.

El resultado son 324,603 transacciones de 5,991 tarjetas a lo largo de 120 días, con 1.197 % de fraude. Cada tarjeta tiene perfil propio: frecuencia de uso, monto típico, horario y comercios habituales. Sobre ese tráfico se inyectan tres mecanismos:

Mecanismo	Patrón	¿Depende del orden?
F1 — escalada	Varias compras pequeñas de prueba, en montos crecientes, y enseguida el golpe grande	Sí. Los mismos montos en otro orden son una compra legítima
F2 — ráfaga	Muchos cargos en pocos minutos, comercios distintos, desde el extranjero	Parcialmente: pesa la densidad temporal
F3 — atípico	Un solo cargo muy por encima del monto habitual de esa tarjeta	No. Es el control del experimento

El control que hace honesta toda la comparación

Junto a cada escalada fraudulenta generamos dos sesiones legítimas con los mismos montos, la misma ventana de tiempo, los mismos comercios nuevos y el mismo canal, pero en orden no creciente. El efecto es que las variables de ventana quedan indistinguibles entre fraude y no fraude:

	Eventos	Suma	Promedio	Máximo	Comercios	Duración	% creciente
F1 — escalada (fraude)	5.03	Q1,303	Q265	Q1,203	5.03	18.2 min	99.7 %
Sesión legítima (control)	5.03	Q1,327	Q270	Q1,225	5.03	18.1 min	0.0 %

Todo coincide salvo una cosa: la secuencia. Sin este control, “varias compras chicas y una grande” se detectaría mirando el promedio de la ventana y el orden no tendría nada que aportar. Con él, la única diferencia sistemática es el orden en que ocurrieron.

Protocolo temporal y controles contra fuga

La partición respeta el tiempo: el 60 % más antiguo entrena, el 20 % siguiente valida, el 20 % final prueba. Entre particiones hay una franja de embargo de dos días cuyos eventos no se usan, para que ningún episodio de fraude quede partido en dos.

Partición	Secuencias	Fraudes	Período	Tasa
Entrenamiento	177,033	2,291	01 ene – 13 mar	1.294 %
Validación	59,495	660	16 mar – 06 abr	1.109 %
Prueba	59,410	644	09 abr – 30 abr	1.084 %
Descartadas (embargo)	10,732	111	—	—

Siete controles verifican automáticamente que no haya fuga de información, y detienen la ejecución si alguno falla: orden temporal sin solape, embargo respetado, ningún episodio repartido entre particiones, ninguna secuencia con eventos posteriores al que se está puntuando, una sola tarjeta por secuencia, y fraude presente en las tres particiones. Un séptimo control recalcula todas las variables agregadas sobre un recorte que borra el futuro y exige valores idénticos: si alguna mirara hacia adelante, borrar el futuro la cambiaría.

El conjunto de prueba no intervino en ninguna decisión —ni arquitectura, ni parámetros, ni umbral, ni la apuesta— y se abrió una sola vez.

2. Comparación común: agregados contra secuencia

Los dos modelos comparten datos, partición, horizonte de predicción, tratamiento del desbalance y regla de umbral. Lo único que cambia es la representación. El modelo A recibe 20 variables agregadas —las que el motor actual ya calcula, más razones y un z-score contra la historia de la tarjeta— y nunca ve la secuencia. El modelo B recibe los 20 eventos en orden.

Deliberadamente hicimos que A fuera fuerte: **compite un modelo de árboles contra regresión logística y gana el primero por amplio margen (0.917 contra 0.519)**. Una línea base débil habría hecho lucir bien al modelo secuencial por la razón equivocada.


Modelo (validación)	AUC-PR	Precisión	Exhaustividad	F1	Costo
A — agregadas	0.9171	0.567	0.988	0.720	Q123,240
B — secuencial	0.9226	0.586	0.983	0.735	Q128,640

No reportamos exactitud: con 1.2 % de fraude, predecir “todo legítimo” da 98.8 % de exactitud y cero valor.

Dos advertencias que el comité debe llevarse de esta tabla.

La primera: **el mejor AUC-PR no es el más barato**. B ordena mejor los casos pero, en su punto de operación, cambia 40 falsos positivos menos por 3 falsos negativos más; a Q4,200 contra Q180, ese canje pierde Q5,400. Ordenar modelos por métrica no equivale a ordenarlos por dinero.

La segunda: **la diferencia de 0.0055 no sobrevive el margen de error**. El intervalo de confianza del 95 % va de -0.015 a +0.025 e incluye el cero; en 31 de cada 100 remuestreos, A queda por encima. A nivel global no se puede afirmar que el modelo secuencial sea mejor.



Curvas precisión-exhaustividad sobre validación. A la derecha, la zona de operación ampliada; los puntos marcan el umbral que minimiza el costo esperado. Las curvas se superponen casi por completo.

3. El valor del orden: dos pruebas para refutarnos

Una mejora de métricas no demuestra que el modelo haya leído el orden. Intentamos refutar nuestra propia conclusión con dos pruebas.

Prueba 1 — Permutación controlada

Barajamos el orden dentro de cada secuencia sin cambiar sus eventos ni sus variables agregadas, y volvemos a puntuar con el mismo modelo y el mismo umbral. Si el modelo no usara el orden, el desempeño no debería moverse. Se repitió con cinco semillas.

Variante	AUC-PR	Caída	F1
Orden real	0.9226	—	0.735
Historia barajada	0.6647 ± 0.011	-28.0 %	0.600
Secuencia completa barajada	0.0503 ± 0.001	-94.5 %	0.135

El desempeño se desploma. La caída es más de diez veces el margen de error que acabamos de medir, así que no es ruido. **El modelo secuencial sí usa el orden.**

El desglose por mecanismo es la evidencia más directa de todo el trabajo:

Mecanismo	A (agregadas)	B (orden real)	B (orden barajado)	Efecto del orden
F1 — escalada	0.7355	0.7806	0.3109	-0.470
F2 — ráfaga	0.9494	0.9489	0.4452	-0.504
F3 — atípico (control)	0.7541	0.7540	0.7887	+0.035

El mecanismo que diseñamos sin dependencia del orden es exactamente el único que no se degrada —de hecho mejora levemente—. Eso descarta que la caída venga de un error de programación: si lo fuera, F3 caería igual que los demás.

Prueba 2 — Recorte de la historia

La permutación demuestra que el orden importa, pero no cuánta historia hace falta ni si el modelo la usa donde debería. Recortamos la secuencia a los últimos k eventos. La predicción se deriva del diseño del simulador, no de los resultados: cada mecanismo debería saturar cerca del tamaño de su propio episodio.


Eventos visibles	F1	F2	F3
1	0.281	0.230	0.775
3	0.548	0.932	0.782
6	0.796	0.947	0.769

Eventos visibles	F1	F2	F3
20	0.781	0.949	0.754

Tamaño real de episodio: $F1 = 5.0$ eventos — $F2 = 10.3$ — $F3 = 1.0$

Las tres curvas hacen lo que el diseño predice. **La escalada satura en 6 eventos**, que es justo el tamaño de sus episodios: el modelo necesita ver el patrón completo y ni un evento más. La ráfaga se resuelve con 3 cargos pese a tener episodios de 10, porque para reconocer una ráfaga basta ver unos pocos cargos pegados. **El atípico vale 0.775 con un solo evento** —el 98 % de su máximo— y de ahí empeora: no hay historia que leer.

Que el punto de saturación de cada mecanismo coincida con su tamaño de episodio es lo que distingue “el modelo lee el patrón que decimos” de “el modelo encontró un atajo”.



Desempeño según la cantidad de historia visible. Izquierda: global, con la línea base como referencia. Derecha: por mecanismo; las líneas punteadas horizontales son el modelo de agregados y las verticales marcan el tamaño medio de cada episodio.

Hallazgo operativo: el mejor desempeño global no se obtiene con 20 eventos sino con 6. Una ventana más corta daría el mismo resultado con un tercio de los datos en línea. Queda como candidato a probar, no como conclusión: la diferencia es menor que el margen de error.

4. La apuesta del equipo: un modelo híbrido

Antes de entrenar nada declaramos por escrito, y registramos en el control de versiones, la siguiente apuesta: que darle al modelo secuencial las variables agregadas junto con el estado de la secuencia mejoraría el desempeño, porque las dos representaciones aciertan en mecanismos distintos y no se solapan. El criterio de éxito, fijado de antemano, era superar al mejor de A y B por al menos 0.02 de AUC-PR con un intervalo de confianza que excluyera el cero.

Condición declarada antes de entrenar	Exigido	Obtenido	Resultado
AUC-PR en validación	≥ 0.9426	0.9424	No cumple, por 0.0002
Intervalo de confianza excluye el cero	Sí	[+0.010, +0.034]	Cumple

Veredicto: la apuesta no cumple el criterio. Falla por dos diezmilésimas. Lo reportamos así porque mover el listón después de ver el resultado destruiría el valor de haberlo fijado antes; el historial de versiones prueba que el número se declaró primero.

El experimento, sin embargo, no fue estéril. La mejora es real —el intervalo está entero por encima de cero— y el razonamiento se confirma donde dijimos que se confirmaría: en el fraude de monto atípico, que es el que necesita la referencia histórica, el híbrido le saca 0.033 a su control.

El control experimental cambió la conclusión.


Comparamos el híbrido contra la misma red entrenada igual pero con las variables agregadas puestas en ceros. Si

lo hubiéramos comparado contra el modelo secuencial simple —lo intuitivo— habríamos atribuido a las agregadas una mejora de +0.0198. El control muestra que solo **+0.0094** viene de ellas: el resto lo aporta un cambio de arquitectura que también está en el control. **Sin control habríamos exagerado el efecto al doble.**

5. La decisión económica

Un fraude no detectado cuesta Q4,200; bloquear una transacción legítima cuesta Q180. La razón es de 23 a 1, así que el óptimo económico está lejos del que maximizaría el F1: conviene alertar de más y aceptar precisión baja.

Elegimos el umbral barriendo validación y seleccionamos como candidato el modelo de menor costo — el híbrido, con Q89,520. Recién entonces abrimos el conjunto de prueba, una vez:



Costo esperado sobre validación para cada umbral posible. El punto marca el mínimo de cada modelo; la línea punteada es el costo de no bloquear nada.

Modelo (prueba)	AUC-PR	Fraudes no detectados	Costo por fraude	Bloqueos indebidos	Costo por bloqueo	Costo total
A — agregadas	0.9092	8	Q33,600	429	Q77,220	Q110,820
B — secuencial	0.9206	12	Q50,400	419	Q75,420	Q125,820
C — híbrido	0.9361	15	Q63,000	379	Q68,220	Q131,220

El orden por costo se invirtió. El candidato elegido en validación resultó el más caro en prueba. Antes de aceptar esa conclusión conviene ver de qué está hecha: toda la diferencia entre el mejor y el peor modelo son 7 fraudes sobre 644. El híbrido alerta mejor —50 bloqueos indebidos menos— pero se le escapan siete casos más, y a 23 a 1 ese canje pierde.

Un resultado que descansa en siete eventos merece un intervalo antes que un titular:

Diferencia de costo en prueba	Observada	Intervalo 95 %	Prob. de que se invierta
B contra A	+Q15,000	[-Q28,510, +Q65,224]	29 %
C contra A	+Q20,400	[-Q29,889, +Q91,083]	26 %
C contra B	+Q5,400	[-Q48,902, +Q76,146]	44 %

Los tres intervalos cruzan el cero. La lectura correcta no es “el motor actual es más barato”, sino que con este volumen de datos el costo no resuelve la comparación. En cambio, el AUC-PR mantuvo el mismo orden en validación y en prueba: el criterio estable para elegir modelo es la métrica de ordenamiento; el umbral habrá que recalibrarlo periódicamente en operación. De hecho el híbrido pasó de 4 fraudes no detectados en validación a 15 en prueba con el mismo umbral, lo que muestra hasta qué punto un umbral puntual se ajusta al período en que se eligió.

Cuánto significa al mes, y bajo qué supuesto

Escalando el período de prueba a la cartera de 1.4 millones de tarjetas y a un mes: el motor de agregados operaría en torno a Q35 millones mensuales de costo total por fraude y bloqueos, frente a Q862 millones si no se bloqueara nada. El híbrido quedaría unos Q6.5 millones por encima, diferencia que —como acabamos de ver— no es distinguible del ruido.

Advertencia sobre estas cifras: el simulador tiene 1.2 % de fraude por transacción, muy por encima de una cartera real. Los montos absolutos están inflados y no son trasladables; léanse las diferencias relativas y la forma de la decisión, no los quetzales.

La recomendación depende del supuesto de costo, y conviene decirlo con números:

Si un fraude no detectado costara...	Q1,500	Q2,500	Q4,200	Q6,000	Q9,000
Modelo más barato	B	B	A	A	A

Por debajo de unos Q2,500 el umbral óptimo se vuelve más estricto y ahí manda la precisión, que es donde el modelo secuencial gana. Si el comité revisara a la baja el costo de un fraude, la recomendación cambiaría.

6. Recomendación y límites

Complementar, no reemplazar.

Conservar el motor de agregados como decisor de bloqueo e incorporar el puntaje secuencial como señal secundaria para priorizar la cola de revisión manual, no para bloquear por sí solo.

Por qué no reemplazar. El modelo secuencial demostró que usa el orden y que ese uso está concentrado donde se diseñó que estuviera. Pero nada de eso se tradujo en un ahorro demostrable: en prueba ningún modelo es más barato que otro dentro del margen de error, y el candidato elegido por costo de validación resultó el más caro. Cambiar un motor en producción exige más que una mejora que no se puede medir.

Por qué no descartar. El orden aporta información real y localizada: en la escalada, el modelo híbrido C alcanza 0.83 de AUC-PR frente a 0.74 del modelo de agregados; el modelo secuencial B alcanza 0.78. La permutación confirma que esa ventaja viene de la secuencia. Esa señal existe aunque hoy no se pague sola, y es precisamente el patrón que el área de riesgos venía señalando.

Un patrón de error concreto

En el punto de operación, el híbrido deja pasar 15 fraudes contra 8 del motor actual: gana precisión y pierde exhaustividad, justo al revés de lo que conviene cuando un fraude cuesta 23 veces más que un bloqueo indebido. Si se incorporara, habría que fijar su umbral con exhaustividad como restricción dura, no dejar que el óptimo teórico lo decida.

Además hay un error irreducible por diseño: las primeras compras de prueba de una escalada no son detectables por nadie. La tarjeta ya está comprometida, pero en ese momento no existe todavía historia que delate el patrón. Ningún modelo, por sofisticado que sea, puede alertar ahí; con un solo evento visible el desempeño sobre la escalada cae a 0.28.

Condiciones bajo las que cambiaríamos la recomendación

- Si un fraude no detectado costara menos de unos Q2,500, el modelo secuencial pasa a ser el más barato y convendría incorporarlo como decisor.
- Si la escalada creciera como proporción del fraude. Hoy es el 45 % de los episodios; si el fraude migrara hacia ese patrón —lo habitual cuando los defraudadores aprenden a evadir un motor de ventanas— la ventaja del orden empezaría a valer dinero.
- Con un conjunto de evaluación mayor. La decisión descansa hoy en 7 fraudes de diferencia. Un período con diez veces más casos podría resolver lo que este no resuelve.

Límites de este estudio

- Los datos son sintéticos. Los mecanismos de fraude son los que nosotros diseñamos, y el modelo secuencial gana justamente en el que construimos para que dependiera del orden. Eso valida la metodología; no prueba que el fraude real se comporte así.
- Las cifras mensuales están infladas por una prevalencia de fraude superior a la real.
- La extrapolación supone que una tarjeta simulada se comporta como una real y que la tasa de fraude del período se sostiene. Ninguna de las dos cosas está verificada.
- El simulador reparte los episodios de fraude uniformemente entre tarjetas, lo que produce más fraude por transacción en tarjetas poco activas de lo que ocurriría en la realidad. Medimos el efecto y es de 0.0003 de AUC-PR, pero existe y favorece al motor de agregados.

Próximo paso recomendado

Ejecutar el puntaje secuencial en sombra sobre transacciones reales durante un trimestre, sin que tome decisiones, y medir dos cosas: si el patrón de escalada aparece en la cartera con frecuencia suficiente, y si el orden de las alertas que produce coincide con los casos que el equipo de revisión confirma como fraude. Eso responde con datos propios del banco la pregunta que este estudio solo pudo responder en simulación.

7. Matriz de evidencias

Evidencia	Figura o tabla	Conclusión	Limitación
1. Integridad de datos	1.1-1.4: composición, partición, 6 controles antifuga, control de causalidad	324,603 transacciones, 1.197 % de fraude, partición temporal con embargo de 2 días; siete controles automáticos verifican que no haya fuga y detienen la ejecución si fallan.	Datos sintéticos; el simulador reparte episodios uniformemente entre tarjetas, lo que sobrerrepresenta el fraude en tarjetas poco activas.
2. Comparación común	2.3: tabla de AUC-PR y umbral, pr_A_vs_B.png, bootstrap	El modelo secuencial obtiene 0.9226 contra 0.9171, pero el intervalo de confianza de la diferencia incluye el cero: no hay ventaja global demostrable.	660 fraudes en validación; el poder estadístico no alcanza para diferencias menores a ± 0.02 .
3. Valor del orden	3.1 permutación, permutacion_por_mecanismo.png; 3.2 recorte, recorte_historia.png	Barajar el orden cuesta el 28 % del desempeño. La escalada se desploma (-0.47) y el fraude atípico no se degrada (+0.03), tal como se había predicho antes de entrenar.	La permutación altera a la vez el orden y la coherencia de los intervalos de tiempo, así que en la ráfaga no separa ambos efectos.
4. Apuesta del equipo	4.1 hipótesis previa, 4.3 veredicto y tabla por mecanismo	No cumple por 0.0002 (0.9424 frente a 0.9426 exigido). La mejora es real pero el control demuestra que solo +0.0094 proviene de las variables agregadas.	Sin el control experimental se habría atribuido a las agregadas el doble del efecto real.
5. Decisión económica	5.1 costo_umbral.png, 5.2 aplicación única a prueba, 5.3 proyección y sensibilidad	Candidato elegido en validación (Q89,520) resulta el más caro en prueba (Q131,220 frente a Q110,820). Los tres intervalos de diferencia de costo cruzan el cero.	Toda la diferencia son 7 fraudes sobre 644; los montos mensuales están inflados por la prevalencia del simulador.
6. Recomendación y límites	5.4	Complementar, no reemplazar: el orden aporta información demostrable pero ningún modelo muestra un ahorro medible con los datos disponibles.	La recomendación se invierte si el costo de un fraude baja de ~Q2,500 o si la escalada crece como proporción del fraude.

El detalle técnico, el código y los resultados reproducibles están en el cuaderno proyecto1 Gualim Ocaña.ipynb. Una sola semilla gobierna toda la generación de datos y el entrenamiento; el estudio completo se reproduce con un comando.