

¿Vale la pena leer el orden de las transacciones?

«Cuando revisamos los casos que se nos escaparon, el patrón siempre está ahí. No en los montos: en el orden en que ocurrieron.»

El comité no pidió una arquitectura. Pidió **decidir si vale la pena incorporar un modelo de secuencias**. Por eso no traemos un modelo: traemos una investigación con tres preguntas, dos pruebas diseñadas para **refutar nuestra propia conclusión**, y una respuesta en quetzales.

1 · LOS DATOS

Simulador propio con tres fraudes y un control que hace honesta la comparación

2 · A CONTRA B

Agregados de ventana frente a secuencia, bajo el mismo protocolo

3 · ¿USÓ EL ORDEN?

Permutación controlada y recorte de la historia

4 · ¿CUÁNTO VALE?

Umbral por costo, prueba única y recomendación

Tres preguntas, y no dicen lo mismo

PREGUNTA	RESPUESTA	DÓNDE VERLO
¿El orden aporta información?	Sí, demostrado. Barajarlo cuesta el 28 % del desempeño	README §3.5 celda 77
¿Bajo qué condiciones?	Solo en un mecanismo. En la escalada: 0.78 contra 0.74. En el monto atípico: empate exacto, 0.754 contra 0.754	README §3.5 celda 80
¿Cuánto vale en quetzales?	No se puede afirmar que valga. Los tres intervalos de costo cruzan el cero	README §3.8 celda 106

Recomendación: complementar, no reemplazar. Que un modelo use el orden no implica que ese uso se pague solo. Las dos cosas son ciertas a la vez, y presentar solo la primera sería deshonesto.

El control que hace honesta la comparación

Elegimos la **Ruta A**, simulador propio, porque permite algo que ningún dataset real permite: **saber con certeza cuál fraude depende del orden y cuál no**.

324,603 transacciones · 5,991 tarjetas · 120 días · 1.197 % de fraude.

Junto a cada **escalada** generamos dos **sesiones legítimas**: mismos montos, misma ventana, mismos comercios, mismo canal — *pero en otro orden*.

Partición **temporal** con embargo de 2 días. Siete controles automáticos contra fuga: son aserciones, detienen la ejecución si fallan. La prueba se abrió **una sola vez**.



IDÉNTICOS

suma 5.03
máximo ≈ Q1,2k
comercios 5.03
ventana 18 min

SOLO DIFIERE

el orden

Sin este control, «compras chicas y una grande» se detecta mirando el promedio de la ventana y el orden no aportaría nada.


Agregados contra secuencia: casi empate

VALIDACIÓN	AUC - PR	F1	COSTO
A — agregadas	0.9171	0.720	Q123,240
B — secuencial	0.9226	0.735	Q128,640

Hicimos que **A fuera fuerte** a propósito: árboles contra logística, 0.917 frente a 0.519. Una línea base débil habría hecho lucir bien a B por la razón equivocada.

El mejor AUC-PR no es el más barato. B cambia 40 falsos positivos menos por 3 falsos negativos más; a Q4,200 contra Q180 ese canje pierde Q5,400.

Diferencia B – A: +0.0055 · IC 95 %: [–0.0148, +0.0254]
Incluye el cero: no hay ventaja global demostrable.



Destruimos el orden y el modelo se derrumbó

Barajamos el orden dentro de cada secuencia sin cambiar sus eventos ni sus agregadas, y volvimos a puntuar con el mismo modelo y umbral. Cinco semillas.

ORDEN REAL

← el evento que se puntúa queda fijo

MISMOS EVENTOS, OTRO ORDEN


-28 %

del AUC-PR al barajar la historia (0.9226 → 0.6647).
Diez veces más que el margen de error.

MECANISMO	ORDEN REAL	BARAJADO	EFECTO
F1 — escalada	0.781	0.311	-0.470
F2 — ráfaga	0.949	0.445	-0.504
F3 — atípico (control)	0.754	0.789	+0.035

El mecanismo diseñado sin orden es el único que no se degrada. Si fuera un error de código, caería igual que los demás.

Efecto de destruir el orden, por mecanismo




Cada mecanismo satura donde su episodio predice

Recortamos la historia a los últimos k eventos. La predicción se derivó del tamaño de episodio de cada mecanismo **antes** de correr nada.

EVENTOS	F1	F2	F3
1	0.281	0.230	0.775
3	0.548	0.932	0.782
6	0.796	0.947	0.769
20	0.781	0.949	0.754

Tamaño real de episodio: $F1 = 5.0 \cdot F2 = 10.3 \cdot F3 = 1.0$

La escalada satura en 6, su propio tamaño. Con un solo evento B cae a 0.597 contra 0.917 de A: **sin historia es peor que la línea base.**



Falló por 0.0002 — y lo reportamos así

Declaramos por escrito y registramos en git, **antes de entrenar**: el híbrido debía superar al mejor de A y B por ≥ 0.02 con intervalo que excluyera el cero.

CONDICIÓN	EXIGIDO	OBTENIDO
AUC-PR validación	≥ 0.9426	0.9424 X
Intervalo excluye cero	Sí	[+0.010, +0.034] ✓

Mover el listón después de ver el número habría destruido el valor de fijarlo antes. El historial de versiones prueba cuál vino primero.

El criterio salió del margen de error medido en la evidencia 2: por debajo de 0.02 no sabríamos distinguir una mejora del ruido.

Lo que sí demostró el control experimental.

Contra el modelo secuencial simple, el híbrido *parecía* mejorar +0.0198

Contra su control real —la misma red con las agregadas en ceros— la mejora es +0.0094.

contra B (mezcla dos cambios)
.0198


contra el control (aísla las agregadas)
.0094

2× habríamos exagerado el efecto sin control experimental. El resto lo aportaba el cambio de arquitectura, que también está en el control.

El costo no resuelve la comparación

PRUEBA · UNA SOLA VEZ	AUC-PR	FRAUDES PERDIDOS	COSTO
A — agregadas	0.9092	8	Q110,820
B — secuencial	0.9206	12	Q125,820
C — híbrido	0.9361	15	Q131,220

El candidato elegido en validación resultó el más caro. Pero toda la diferencia son **7 fraudes** sobre 644, y los tres intervalos de costo **cruzan el cero**.



El AUC-PR sí mantuvo su orden entre validación y prueba; el costo no. Elijan modelo por la métrica estable y recalibren el umbral en operación.

Complementar, no reemplazar. El motor de agregados sigue decidiendo el bloqueo; el puntaje secuencial prioriza la cola de revisión.

Cambiaríamos de opinión si:

- un fraude no detectado costara menos de **~Q2,500** — ahí gana el secuencial;
- la escalada creciera como proporción del fraude (hoy 45 % de los episodios);
- tuviéramos **10x más casos** para resolver la comparación de costos.

Próximo paso: correr el puntaje en sombra un trimestre sobre transacciones reales, sin que decida, y medir si el patrón existe en la cartera.